
Exploratory Data Analysis – Amazon Products Dataset

Análisis de productos y reseñas

Adolfo José Montes de Oca López

1-4-2026

Python (Pandas, Matplotlib)

1. INTRODUCCIÓN

El presente análisis exploratorio de datos (EDA) tiene como objetivo examinar un conjunto de productos y reseñas obtenidas de Amazon, con el fin de identificar patrones relevantes en precios, valoraciones y comportamiento de los usuarios.

A través del uso de herramientas de análisis de datos en Python, se busca comprender la relación entre variables clave como el precio, la calificación del producto y la cantidad de reseñas, así como evaluar la calidad y confiabilidad de los datos recopilados.

Este análisis permitirá generar insights que sirvan como base para la toma de decisiones y el desarrollo de visualizaciones interactivas en etapas posteriores del proyecto.

2. METODOLOGÍA

El proyecto se desarrolló en las siguientes etapas:

Recolección de datos

- Web scraping de productos desde Amazon
- Extracción de:
 - Información del producto (precio, rating, reviews)
 - Reseñas individuales

Limpieza de datos

- Eliminación de:
 - Duplicados (ASIN y reviews)
 - Valores nulos o inválidos
 - Outliers en precios
- Normalización:
 - Conversión de precios a una sola divisa (USD)
 - Formato de fechas
 - Limpieza de texto

Dataset final

- **179 productos**
- **825 reviews**



3. DESCRIPCIÓN DEL DATASET

- Número de productos: 179
- Número de reviews: 825
- Variables (Products):
ASIN, Price, Rating, Review Count, Date
- Variables (Reviews)
Review Title, Stars, Review Body, Verified Purchase, Review Date

4. ANÁLISIS EXPLORATORIO (EDA)

4.1 Análisis de precios

- Precio promedio: 17.61 USD
- Rango principal: 15-20 USD
- Desviación estándar baja → mercado homogéneo




Insight:

Existe una clara saturación del mercado en el rango de 15-20 USD, lo que sugiere alta competencia y baja diferenciación basada en precio.

4.2 Análisis de ratings

- Rating promedio: **4.61**
- Distribución concentrada en **4.5 – 5**




Insight:

Existe un claro sesgo positivo en las valoraciones, lo que dificulta diferenciar productos únicamente por rating.

4.3 Relación precio vs rating

- No se observa correlación clara




Insight:

El precio no es un factor determinante en la percepción de calidad del producto.

4.4 Popularidad (Review Count)

- Alta dispersión (std: 1270)
- Pocos productos con muchas reviews
- Muchos productos con pocas reviews




Insight:

La distribución sigue un patrón de “long tail”, donde pocos productos concentran la mayoría de la atención.

4.5 Análisis de reviews

- Promedio de estrellas: **4.62**
- Más de 75% de reviews son de 5 estrellas



Insight:

Las reseñas muestran un comportamiento altamente positivo, consistente con el rating general.

4.6 Verified Purchase


- 817 de 825 reviews son verificadas (>98%)

Insight:

La alta proporción de compras verificadas indica alta confiabilidad en los datos.

4.7 Evolución temporal

- Incremento notable de reviews en 2025




Insight:

Se observa un crecimiento en la actividad de los usuarios, posiblemente relacionado con tendencias de mercado o mayor exposición de los productos.

4.8 Rating vs promedio de reviews

- Alta consistencia entre ambas métricas




Insight:

El rating mostrado por Amazon refleja de manera confiable el promedio real de las reseñas.

4.9 Reviews por producto

- La mayoría de productos tienen pocas reviews en el dataset



Nota importante:

Este comportamiento está influenciado por la limitación del scraping (no se extrajeron todas las páginas de reviews).

5. HALLAZGOS CLAVE

5.1 Concentración de precios en un rango competitivo

El análisis de precios muestra una fuerte concentración de productos dentro del rango de **15 a 20 USD**, con una media de aproximadamente **17.6 USD** y baja dispersión.

Esto indica que existe un estándar de mercado bien definido, donde la mayoría de los vendedores compiten en niveles de precio similares, limitando la diferenciación por costo.

5.2 Alta valoración generalizada (sesgo positivo)

Tanto a nivel de productos como de reseñas, se observa una calificación promedio superior a **4.6 estrellas**, con una baja variabilidad.

Esto sugiere un **sesgo positivo en las valoraciones**, donde la mayoría de los productos son percibidos como satisfactorios o de buena calidad, reduciendo el impacto del rating como factor diferenciador.

5.3 Desigualdad en la distribución de reseñas

La distribución del número de reseñas presenta una alta dispersión, con pocos productos acumulando un volumen significativamente mayor de reviews, mientras que la mayoría cuenta con pocas.

Este comportamiento indica una dinámica de mercado tipo **“long tail”**, donde la visibilidad y popularidad están concentrados en un subconjunto reducido de productos.

5.4 Baja relación entre precio y valoración

El análisis de dispersión entre precio y rating muestra que no existe una correlación clara entre ambas variables.

Productos con precios bajos pueden tener valoraciones altas, al igual que productos en rangos superiores, lo que sugiere que el precio no es factor determinante en la percepción de calidad.

5.5 Alta confiabilidad de las reseñas

Se identificó que la gran mayoría de las reseñas corresponden a **compras verificadas**, lo que refuerza la credibilidad de los datos analizados.

Esto permite asumir que las valoraciones reflejan de manera consistente la experiencia real de los usuarios.

5.6 Consistencia entre ratings de producto y reviews

El promedio de rating a nivel producto (**4.61**) y el promedio de estrellas en reviews (**4.62**) son prácticamente idénticos.

Esto valida la consistencia interna del dataset y sugiere que las métricas agregadas reflejan adecuadamente la percepción individual de los usuarios.

5.7 Crecimiento reciente en la actividad de reseñas

El análisis temporal evidencia un incremento notable en la cantidad de reseñas en periodos recientes, particularmente hacia el año 2025.

Esto puede indicar un aumento en la demanda del producto o una mayor actividad dentro del mercado en ese periodo.

5.8 Posibles productos duplicados a nivel comercial

Se identificaron productos con diferentes ASIN pero características prácticamente idénticas (título, precio, rating y número de reseñas).

Esto sugiere la posible existencia de:

- Variantes del mismo producto
- Duplicación de listings
- Estrategias de segmentación dentro del Marketplace

Este fenómeno puede influir en la competencia interna y en la distribución de reseñas.

6. RECOMENDACIONES (NIVEL NEGOCIO)

6.1 Estrategia de precios

Dado que la mayoría de los productos se concentran en un rango de **15.-20 USD**, se recomienda posicionar los productos dentro de este intervalo para mantener competitividad en el mercado.

Salir de este rango podría reducir la probabilidad de conversión, ya que los consumidores parecen estar habituados a este nivel de precios

6.2 Diferenciación

Debido a la baja variabilidad en las valoraciones (la mayoría de los productos cuentan con ratings superiores a 4.5), el rating no representa un factor diferenciador relevante.

Por lo tanto, se recomienda enfocar los esfuerzos en elementos como:

- Branding
- Diseño del producto
- Presentación visual
- Descripción optimizada

Estos factores pueden influir más en la decisión de compra que pequeñas diferencias en la calificación.

6.3 Estrategia de adquisición de reviews

El análisis muestra una distribución tipo “long tail”, donde pocos productos concentran la mayoría de las reseñas.

Esto sugiere un efecto de “winner takes all”, en el cual los productos con mayor número de reviews obtienen mayor visibilidad.

Se recomienda implementar estrategias para **acelerar la obtención de reseñas en etapas tempranas**, tales como:

- Promociones de lanzamiento
- Incentivos iniciales (dentro de políticas de la plataforma)
- Campañas de marketing dirigidas

El objetivo es alcanzar rápidamente un volumen crítico de reviews que permita competir con productos consolidados.

6.4 Estrategia de visibilidad

Dado que la visibilidad parece estar altamente influenciada por el volumen de reviews, es fundamental priorizar acciones que incrementen la exposición del producto.

Se recomienda:

- Optimizar listados (SEO dentro de la plataforma)
- Utilizar palabras clave relevantes
- Mejorar títulos y descripciones
- Invertir en publicidad dentro de la plataforma

Esto permitirá aumentar el tráfico hacia el producto y, en consecuencia, la generación de nuevas reseñas.

6.5 Gestión de reputación

Aunque los ratings son generalmente altos, mantener esta percepción positiva sigue siendo clave.

Se recomienda:

- Asegurar consistencia en la calidad del producto
- Monitorear feedback de clientes
- Responder a reseñas cuando sea posible

Una caída en el rating, aunque pequeña, puede afectar la confianza del consumidor en un mercado altamente competitivo.

6.6 Confianza del cliente

Dado que más del **98% de las reseñas provienen de compras verificadas**, se puede concluir que la confianza del usuario es un factor relevante en la percepción del producto.

Se recomienda mantener prácticas que refuercen esta confianza, como:

- Transparencia en la información del producto
- Cumplimiento de expectativas del cliente
- Calidad consistente en la entrega

7. Limitaciones

- Scraping sin paginación completa de reviews
- Posible sesgo positivo en valoraciones
- Variantes de productos (mismo producto, distinto ASIN)

8. Conclusión

El análisis realizado permite concluir que los productos evaluados presentan, en su mayoría, una alta valoración por parte de los usuarios, con un promedio superior a 4.6 estrellas tanto a nivel de producto como de reseñas individuales.

En términos de precios, se observa una concentración significativa en un rango accesible (15–20 USD), lo que sugiere que los productos analizados pertenecen a una categoría de bajo costo.

No se identificó una relación directa entre el precio y la calificación del producto, indicando que factores distintos al precio influyen en la percepción del usuario.

Asimismo, se detectó una distribución desigual en la cantidad de reseñas, donde un pequeño grupo de productos concentra la mayor parte de la interacción, lo cual es consistente con patrones típicos de popularidad en plataformas digitales.

Finalmente, la alta proporción de compras verificadas refuerza la confiabilidad general de las reseñas analizadas, aunque no se descarta la presencia de sesgos inherentes al tipo de productos evaluados.